

MODELAÇÃO E PREVISÃO DE SÉRIES TEMPORAIS DO PREÇO DO LEITE: UMA ABORDAGEM INTEGRADA COM METODOLOGIAS CLÁSSICAS E TÉCNICAS DE DEEP LEARNING

Simão Pereira¹, Tiago Pereira¹, Tiago Timóteo¹

¹ISCTE – Instituto Universitário de Lisboa, Lisboa, Portugal

Abstract

O presente trabalho tem como objetivo analisar e comparar diferentes métodos de previsão aplicados aos preços do leite nos Estados Unidos, tanto ao nível do consumidor quanto do produtor. Para isso, foram utilizadas duas séries temporais com dados mensais entre 1995 e 2023. A abordagem inclui modelos estatísticos tradicionais, como ARIMA e Exponential Smoothing, bem como técnicas de Deep Learning, nomeadamente redes LSTM. Além disso, foi desenvolvido um modelo híbrido que combina os pontos fortes dos métodos clássicos e das redes neuronais. Após uma análise exploratória e testes de diagnóstico, os modelos foram treinados e avaliados com métricas de erro em diferentes horizontes de previsão. Os resultados indicam que os modelos baseados em redes neuronais, especialmente o híbrido, apresentaram maior precisão em prever oscilações recentes e padrões complexos nos dados. Esta combinação de abordagens mostrou-se eficaz, com potencial para apoiar decisões estratégicas no setor agroalimentar, incluindo planeamento da produção, negociações de preços e formulação de políticas públicas.

Keywords: LSTM, ARIMA, Exponential Smoothing, séries temporais, preço do leite, modelo híbrido

1. INTRODUÇÃO

Os preços dos alimentos afetam diretamente o dia a dia de milhões de pessoas desde produtores rurais até consumidores finais. Entre os produtos mais sensíveis a variações económicas está o leite, um bem essencial cuja cadeia de produção depende de fatores complexos como políticas agrícolas, custos logísticos e choques globais, como crises económicas e conflitos. Compreender e prever os seus preços ao longo do tempo não é apenas um exercício técnico: é uma necessidade prática para garantir estabilidade, planeamento e segurança alimentar.

Foi com essa motivação que este estudo foi desenvolvido. Analisámos duas séries temporais relativas ao preço do leite nos Estados Unidos tanto ao nível do produtor quanto do consumidor, com dados mensais recolhidos entre janeiro de 1995 e março de 2023 na base FRED (Federal Reserve Bank of St. Louis). O objetivo é claro: identificar qual abordagem preditiva consegue oferecer previsões mais fiáveis para esse tipo de série económica.

Para isso, combinamos diferentes métodos: desde os modelos estatísticos clássicos, como ARIMA e Exponential Smoothing (Hyndman, 2021), até técnicas mais modernas de deep learning, com redes neurais do tipo LSTM. Acreditamos que nenhuma abordagem, sozinha, capta toda a complexidade desses dados. Por isso, também desenvolvemos um modelo híbrido uma solução que une o melhor dos dois mundos, ao integrar padrões lineares e não lineares de forma complementar (Ramos, 2021).

Mais do que comparar algoritmos, este estudo pretende mostrar como métodos analíticos, bem aplicados, podem transformar dados históricos em conhecimento útil. Seja para ajudar produtores a planearem a sua produção, empresas a preverem custos ou autoridades a delinearem políticas públicas, previsões mais precisas podem fazer a diferença. Este artigo está estruturado da seguinte forma: a Secção 2 apresenta os principais conceitos teóricos; a Secção 3 detalha os dados e a metodologia adotada; a Secção 4 apresenta os resultados das previsões; a Secção 5 discute as implicações desses resultados; e a Secção 6 encerra com as conclusões e propostas para futuras investigações.

2. ENQUADRAMENTO TEÓRICO

2.1. Modelos ARIMA

Os modelos ARIMA (*Autoregressive Integrated Moving Average*) são uma classe de modelos usados para previsão de séries temporais. São aplicados quando uma série é não estacionária, mas poderá ser por diferenças. O modelo é definido por $ARIMA(p, d, q)$, onde d representa o número de diferenças necessárias para tornar a série estacionária, p a ordem da componente *autoregressive* e q a ordem da componente *moving average*.

2.2. Modelos de alisamento exponencial

Os modelos de alisamento exponencial baseiam-se em médias ponderadas das observações anteriores. Os pesos podem, ou não, decrescer exponencialmente à medida que as observações são mais, ou menos, recentes. No modelo mais simples de alisamento exponencial (*single exponential smoothing*), quanto mais recentes as observações, maior é o peso associado. Se o modelo mais simples lida com o comportamento estacionário da série temporal, o *double exponential smoothing* lida com a existência de tendência, e o *triple exponential smoothing* com a existência de sazonalidade. Desta forma, com as componentes de tendência e sazonalidade, existem nove combinações de modelos de alisamento exponencial, descritos na Tabela 1. Cada modelo corresponde a um par de letras (T, S), correspondendo T à componente da tendência e S à componente da sazonalidade.

Tabela 1. Classificação dos modelos de alisamento exponencial

Fonte: Adaptado de Hyndman & Athanasopoulos (2018, Section 7.4).

Componente Tendência (T)	Componente Sazonalidade (S)		
	Nenhum (N)	Modelo Aditivo (A)	Modelo Multiplicativo (M)
Nenhum (N)	(N, N)	(N, A)	(N, M)
Modelo Aditivo (A)	(A, N)	(A, A)	(A, M)
Modelo Aditivo Amortecido (A_d)	(A_d, N)	(A_d, A)	(A_d, M)

2.3. Deep Neural Networks (DNN)

As Redes Neurais Artificiais (ANN), Redes Neurais Recorrentes (RNN) e Long Short-Term Memory (LSTM) são diferentes estruturas de *deep neural networks* com aplicações em diversas áreas, incluindo a análise de séries temporais. A unidade fundamental das ANN é o neurónio, havendo normalmente mais do que um numa arquitetura e em várias camadas. As Multilayer Perceptron (MLP), um tipo de ANN, servem como base para outras arquiteturas. Nas MLPs, é assumido que os dados não têm uma ordem definida, enquanto as RNNs produzem um modelo para dados sequenciais devido ao armazenamento de informação ao longo do tempo, ainda que a curto prazo. As RNNs são particularmente adequadas para dados sequenciais, como séries temporais, devido à sua capacidade de "aprender" dependências temporais. No entanto, as RNNs padrão podem ter dificuldades em reter informações de longo prazo. As LSTMs, um tipo de RNN, são capazes de reter informação de dependências de longo prazo. As diferenças entre estes tipos de redes neuronais residem no neurónio, como se pode observar na Fig. 1.




Fig. 1. Comparação entre os células de: MLP, RNN and LSTM

Fonte: Adaptado de (Ramos, 2021).

3. DADOS E PROCEDIMENTOS METEDOLÓGICOS

3.1 Dados

O presente estudo é baseado em duas séries temporais disponibilizadas publicamente pela base de dados FRED:

- (Federal Reserve Bank of St. Louis), *Average Price: Whole Milk, per Gallon* (U.S. City Average) (APU0000709112). (U.S. Bureau of Labor Statistics via FRED, n.d.-a)

- (Federal Reserve Bank of St. Louis), *Producer Price Index by Industry: Fluid Milk Manufacturing*, (PCU3115113115111). (U.S. Bureau of Labor Statistics via FRED, n.d.-b)

Cada série é univariada e contém uma frequência mensal de janeiro de 1995 a 2023 (data de extração dos dados). No que toca às variáveis, estas contém uma variável numérica correspondente ao índice de preços, ou seja, PCU3115113115111 (Índice de preços ao produtor para leite fluido), APU0000709112 (Preço médio do leite integral por galão ao consumidor).

Estes dados, recolhidos por agências federais dos EUA com metodologias padronizadas e publicados pelo FRED, são de acesso público e não possuem qualquer informação pessoal ou sensível.

3.2 Metodologias

Relativamente às metodologias deste estudo, o processo foi estruturado em três fases principais: análise exploratória dos dados, modelação com técnicas e modelos clássicos de séries temporais e, por fim, aplicação de redes neurais profundas (DNN) para previsão.

3.2.1 Análise Exploratória de Dados

Na fase inicial, procedeu-se à análise exploratória das três séries temporais consideradas. Esta análise teve como objetivo compreender o comportamento global dos dados ao longo do tempo, com particular atenção à identificação de tendências, sazonalidade, outliers e potenciais quebras de estrutura. Para tal, recorreu-se à visualização gráfica das séries e à sua decomposição em componentes (tendência, sazonalidade e ruído). Foram também analisadas funções de autocorrelação e autocorrelação parcial, essenciais para o diagnóstico e configuração dos modelos subsequentes.

Por fim, a análise foi complementada com a aplicação de testes estatísticos de inferência, incluindo o teste *Augmented Dickey-Fuller* e outros testes de estacionaridade, com o objetivo de verificar a adequação das séries aos pressupostos exigidos pelos modelos lineares.

3.2.2. Modelos Clássicos

Na fase seguinte, foram aplicadas técnicas clássicas de modelação de séries temporais, nomeadamente os modelos ARIMA e os modelos de Suavização Exponencial (*exponential smoothing*).

Para ambos os modelos, a separação dos dados para treino e teste respeitou a natureza temporal do problema, sendo reservado um período mais recente para validação. Relativamente ao ARIMA, a escolha dos parâmetros baseou-se na análise dos gráficos ACF (*Autocorrelation Function*) e PACF (*Partial Autocorrelation Function*), bem como numa avaliação dos critérios de informação (AIC, BIC e HQIC) obtidos a partir da estimação de diferentes combinações de parâmetros, através de uma grelha de modelos. Posteriormente, a qualidade das previsões foi avaliada com base em métricas como o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o erro percentual absoluto médio (MAPE).

Relativamente ao modelo de Suavização Exponencial, foram testadas diferentes configurações, incluindo variantes com tendência, sem tendência e com tendência atenuada. Os modelos foram ajustados automaticamente com estimação dos parâmetros de suavização, tendência e atenuação, e avaliados com base em métricas como MAE e MAPE em diferentes períodos futuros. Adicionalmente, foram analisados os resíduos dos modelos ajustados e comparadas as previsões com os dados reais.

3.2.3. DNN

Numa abordagem orientada à aprendizagem profunda, foi desenvolvida uma rede neuronal do tipo LSTM (*Long Short-Term Memory*) com o objetivo de modelar relações não lineares nos dados temporais. Para preparar os dados, as séries foram convertidas para um formato supervisionado através da criação de janelas deslizantes, permitindo que o modelo aprendesse a prever um conjunto de valores futuros com base em observações anteriores. Antes do treino, os dados foram normalizados com a técnica *MinMaxScaler*, aplicada separadamente aos conjuntos de treino e teste para garantir a integridade do processo. A arquitetura da rede incluiu a camada de entrada, uma camada LSTM com 64 unidades sequenciais, e por uma camada densa, correspondente à final, ajustada para prever múltiplos períodos futuros em simultâneo. O modelo foi compilado com a função de perda MAE (erro absoluto médio) e a métrica de avaliação MAPE (erro percentual absoluto médio), e foi treinado com o otimizador Adam, utilizando *early stopping* para interromper o treino quando a performance do conjunto de validação deixasse de melhorar. O modelo foi otimizado por *hyperparameter tuning* com o Optuna, de forma a escolher o *batch_size* e *learning_rate* mais indicados para o problema. Para avaliar a capacidade de generalização do modelo com os valores dos hiper parâmetros anteriormente mencionados, foi utilizada a técnica de validação cruzada *TimeSeriesSplit*, que respeita a ordem cronológica dos dados. O desempenho preditivo foi medido com base nas métricas MAE e MAPE, avaliadas em diferentes prazos de previsão (1, 3 e 12 meses). Por fim, foi realizada a previsão de 12 meses, o que permitiu uma análise comparativa com os modelos estatísticos tradicionais, destacando as vantagens e limitações das redes neurais em contextos temporais.

3.2.4. Modelo Híbrido

Por fim, como abordagem complementar, foi desenvolvido um modelo híbrido que combina modelo ARIMA e uma LSTM, com o objetivo de capturar simultaneamente padrões lineares e não lineares presentes na série temporal. A série temporal foi analisada e pré-processada com base em testes de estacionaridade (ADF, KPSS) e decomposição sazonal (aditiva), com o objetivo de identificar tendências e componentes de ruído. Constatou-se que a série possui uma tendência significativa, mas não apresenta evidência de sazonalidade relevante, permitindo focar a modelação nas componentes de tendência e ruído. Após confirmar a estacionariedade da série diferenciada, foi aplicado um processo de seleção automática de modelos ARIMA com base em critérios de informação (AIC, BIC,

HQIC). O modelo foi ajustado aos dados de treino e gerou previsões tanto dentro da amostra (in-sample) como para o período de teste. Os resíduos da série foram posteriormente utilizados como input para uma rede LSTM com validação cruzada do tipo forward chaining (TimeSeriesSplit). A rede LSTM foi treinada com sequências de lags (número ótimo determinado empiricamente), permitindo capturar dependências temporais complexas nos resíduos. A arquitetura final incluiu uma camada LSTM com 200 unidades seguida de uma camada densa, sendo o modelo treinado com early stiping com base na perda de validação. Após o treino, o modelo foi utilizado para prever os resíduos correspondentes ao conjunto de teste, passo a passo, usando os valores anteriores como entrada. As previsões finais foram obtidas pela soma das previsões da tendência (ARIMA) e dos resíduos (LSTM), garantindo o alinhamento temporal entre os dois conjuntos. Esta combinação permite capturar simultaneamente a estrutura linear e os padrões residuais complexos, oferecendo uma previsão mais robusta. O desempenho preditivo foi medido com base nas métricas MAE e MAPE, avaliadas em diferentes prazos de previsão (1, 3 e 12 meses). Por fim, foi realizada a previsão de 12 meses, o que permitiu uma análise comparativa com os modelos estatísticos tradicionais, destacando as vantagens e limitações das redes neurais em contextos temporais.

4. RESULTADOS

4.1 Análise Exploratória de Dados

Nesta fase, analisaram-se as duas séries temporais relativas ao preço médio do leite ao consumidor (CPI) e ao preço ao produtor (PPI), entre janeiro de 1995 e março de 2023, com o objetivo de avaliar a sua estrutura estatística e preparar a modelação subsequente.

Na primeira série, evidenciada na Fig. 2, é possível observar uma evolução do preço médio do leite ao consumidor nos EUA entre 1995 e 2023.




Fig. 2. Preço médio do leite ao consumidor - Representação gráfica

A série apresenta uma tendência globalmente crescente, com algumas oscilações ao longo do tempo. Destacam-se três períodos críticos: o primeiro em 2007–2008, com um pico seguido de queda, coincidindo com a crise financeira global; o segundo em 2014–2016, quando os preços do leite caíram de forma prolongada devido ao excesso de produção na União Europeia após o fim das quotas sobre a produção de leite; e o terceiro, mais recente, entre 2020 e 2023, marcado pela pandemia de COVID-19, por disrupções logísticas, e pelo aumento generalizado dos custos de produção, agravado pela guerra na Ucrânia, que afetou os preços de energia, fertilizantes e rações, pressionando os custos ao longo de toda a cadeia de abastecimento alimentar, como demonstrado na fig 3.




Fig. 3. Preço médio do leite ao consumidor - Representação gráfica de boxplots anuais

Na segunda série, PPI, representada na Fig. 4, analisa-se o índice de preços ao produtor na indústria de fabrico de leite nos EUA.




Fig. 4. Índice de preços na indústria de fabrico do leite - Representação gráfica

Como demonstrado na Fig.5, entre 2007 e 2014, registam-se flutuações expressivas, com aumentos significativos de preços seguidos de quedas, reflexo de oscilações no custo de produção, alterações na política agrícola e variações no preço de commodities associadas (como por exemplo, milho e soja, usados na alimentação animal). Em 2020, os preços caem no início da pandemia de COVID-19, mas recuperam rapidamente em 2021–2022, atingindo os valores mais altos da série. Este aumento coincide com os efeitos combinados da crise logística, subida dos custos de energia e rações, e o impacto indireto da guerra na Ucrânia, tal como observado na série CPI.




Fig. 5. Índice de preços na indústria de fabrico do leite - Representação gráfica de boxplots anuais

Para complementar a análise descritiva, foram realizados testes estatísticos para avaliar a normalidade, estacionaridade e independência das séries. Como se verifica na tabela 2, ambas apresentam valores de assimetria elevados e, no caso da série CPI, também curtose significativa, indicando desvios da normalidade, que, por sua vez, são confirmados pelo teste de Jarque-Bera, que rejeita a hipótese de normalidade em ambas as séries com elevada significância. Relativamente à estacionaridade, o teste *Augmented Dickey-Fuller* (ADF) não rejeita a hipótese nula de presença de raiz unitária e o teste KPSS rejeita a hipótese nula de estacionaridade, concluindo-se que ambas as séries não são estacionárias. Por fim, o teste BDS revelou evidências de dependência não linear em ambas as séries, rejeitando a hipótese de que os dados são independentes e identicamente distribuídos (i.i.d.). Este resultado indica a presença de estruturas complexas nos dados, que não podem ser captadas por modelos puramente aleatórios. Os resultados obtidos consolidam a necessidade da transformação das séries antes da modelação.

Tabela 2. Testes Estatísticos

		Assimetria	Curtose	Jarque-Bera	ADF	KPSS	BDS
CPI	<i>statistic</i>	3.0105	-2.2075	12.5347	-1.8883	1.5514	60.597-85.634
	<i>p-value</i>	0.0026	0.0273	0.0019	0.0337	-----	0.000
PPI	<i>statistic</i>	3.768	-0.3890	15.5210	-1.6251	2.4847	54.216-77.647
	<i>p-value</i>	0.0002	0.6973	0.0004	0.4701	-----	0.000

4.2 Modelação e Previsão das Séries Temporais

De forma a avaliar a capacidade de previsão a curto e médio prazo dos diferentes modelos desenvolvidos para ambas as séries temporais os modelos foram treinados com dados de janeiro de 1995 até março de 2022, para os modelos clássicos e de *deep learning*, e de janeiro de 1995 até janeiro de 2022, sendo as previsões geradas para os 12 meses seguintes (até março de 2023 e até janeiro de 2023 respetivamente), posteriormente comparadas com os valores reais observados nesse intervalo.

4.2.1 Modelos Clássicos

Para os modelos ARIMA, a seleção dos melhores foi realizada com base nos critérios de informação AIC, BIC e HQIC, sendo que o modelo ARIMA(1, 1, 1) foi consistentemente escolhido para ambas as séries em análise. A Figura.6 apresenta tanto o ajustamento como as previsões de curto e médio prazo para cada uma das séries temporais.

A análise gráfica revela que os diferentes modelos ARIMA apresentam um desempenho semelhante no que respeita ao ajustamento in-sample (à esquerda da linha divisória). Todos os modelos conseguem captar bem a tendência histórica das séries, aproximando-se dos valores reais (linha preta), o que confirma a sua capacidade para representar os padrões de longo prazo.


No entanto, no período de previsão out-of-sample (à direita da linha divisória), nota-se uma clara limitação na capacidade preditiva dos modelos. Todos os modelos tendem a subestimar o crescimento observado, demonstrando alguma rigidez na adaptação a mudanças estruturais recentes. No caso da série PPI, as previsões revelam trajetórias bastante divergentes: enquanto alguns modelos mantêm previsões estacionárias, outros antecipam uma tendência decrescente, o que contrasta com a evolução real, caracterizada inicialmente por um aumento seguido de uma inflexão descendente.

No caso dos modelos de alisamento exponencial (ES), foram testadas três variantes principais: sem tendência (N, N), com tendência aditiva (A, N) e com tendência aditiva atenuada (Ad, N). A escolha destes modelos teve por base a ausência de sazonalidade nas séries temporais em estudo, o que justificou a exclusão de componentes sazonais no processo de modelação.

A análise gráfica dos resultados, apresentada na Figura.7, permite verificar que todos os modelos apresentam um bom ajustamento aos dados reais durante o período de treino (linha preta), captando adequadamente a evolução das séries. Contudo, no horizonte de previsão, observa-se uma divergência entre os modelos.

Tanto na série de preços médios do leite tanto na série do PPI, os três modelos mantêm previsões relativamente estáveis ao longo do tempo, refletindo a tendência dos últimos períodos do treino. O modelo com tendência aditiva (A, N) destaca-se ligeiramente, por estar mais próximo dos valores reais no início do período de teste, embora todos os modelos apresentem alguma subestimação em relação à realidade.

A)



B)

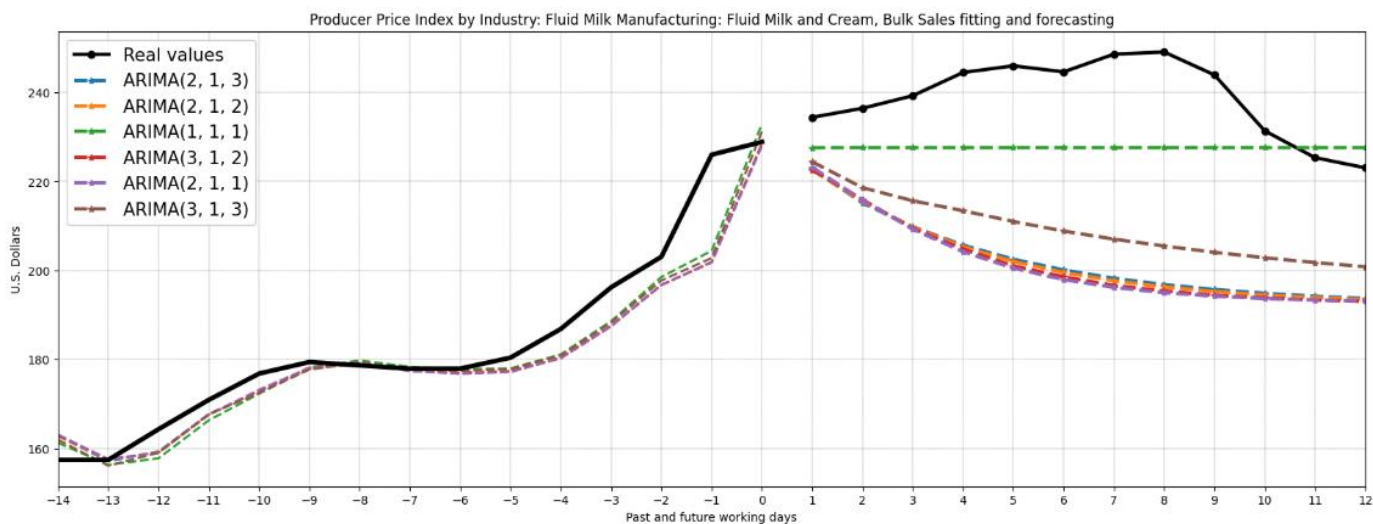


Fig. 6. Moldeo ARIMA(treino e previsão): A preço médio do leite ao consumidor; B PPI

4.2.3 DDN (*LSTM e Modelo Híbrido*)

A Figura 8 e a Figura 9 apresentam os resultados obtidos para os modelos baseados em redes neuronais profundas: (A) o modelo LSTM e (B) o modelo híbrido ARIMA-LSTM, aplicados respectivamente à série do preço médio do leite ao consumidor e à série do índice de preços do produtor (PPI). Em ambas as figuras, é possível observar: (i) a linha com os valores reais da série (linha preta mais espessa); (ii) o conjunto de dados utilizados para o treino dos

modelos, representado pela zona sombreada; (iii) as previsões in-sample (linha laranja) e out-of-sample (linha azul clara), permitindo uma análise comparativa da capacidade de generalização de cada abordagem. É importante salientar que o tamanho da zona de validação difere entre os dois modelos, devido as diferentes metodologias aplicadas.

A análise visual dos gráficos demonstra que o modelo híbrido apresenta um desempenho superior ao modelo LSTM simples, especialmente na fase de previsão out-of-sample. Este modelo consegue captar melhor a dinâmica e o padrão da série temporal, ajustando-se de forma mais precisa às flutuações do período de teste. Embora ambos os modelos sejam capazes de seguir a tendência geral dos dados, o modelo híbrido produz previsões mais suaves, coerentes e próximas dos valores reais, demonstrando, assim, uma melhor capacidade de generalização.

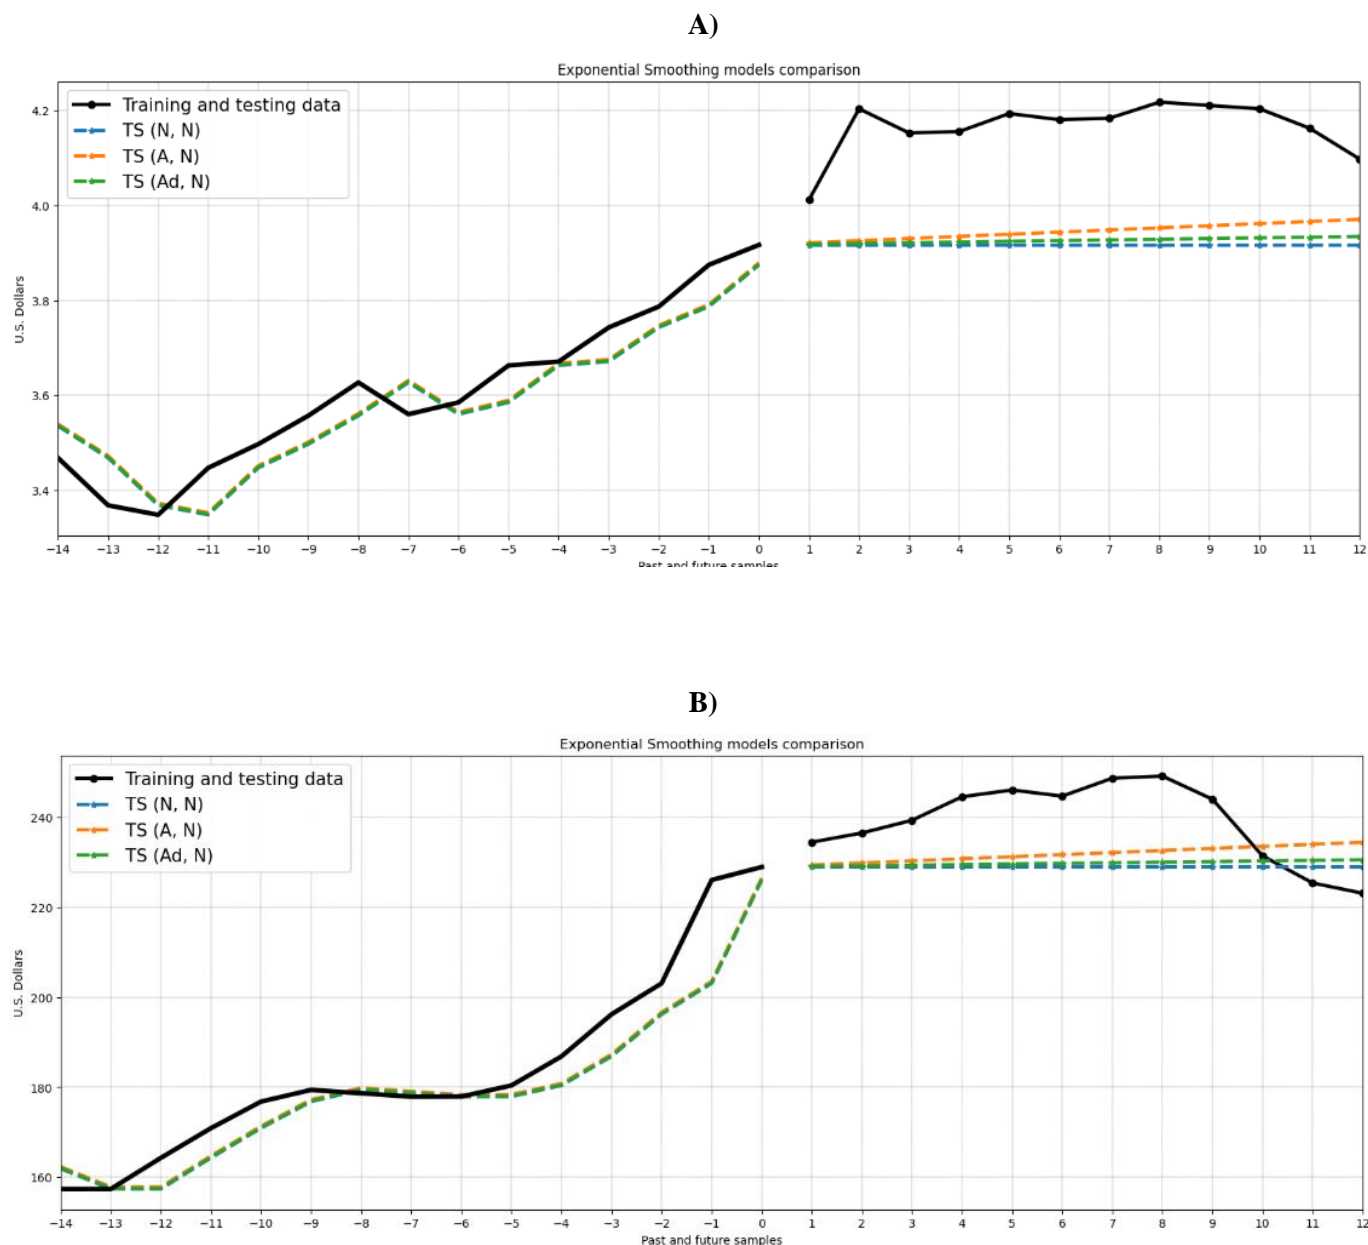


Fig. 7. Moldeo ES (treino e previsão): **A** preço médio do leite ao consumidor; **B** PPI

4.3 Comparação de resultados

A Tabela 3 apresenta os valores de MAPE (%) obtidos pelos diferentes modelos aplicados às duas séries temporais em estudo: a série dos preços ao consumidor (CPI) e a série do índice de preços do produtor (PPI), considerando três horizontes temporais de previsão (1, 3 e 12 meses). Os modelos considerados incluem o ARIMA, os modelos de Alisamento Exponencial (ES), o modelo LSTM e o modelo híbrido ARIMA-LSTM.

Para a série CPI, observa-se que os modelos ARIMA e ES apresentam desempenhos semelhantes em todos os horizontes, com valores de erro entre 2% e 6%. Por outro lado, os modelos baseados em redes neurais profundas (LSTM e híbrido) obtêm erros de previsão significativamente mais baixos, especialmente nos horizontes mais curtos. O modelo LSTM atinge um MAPE mínimo de 0.1578% para a previsão de 1 mês, enquanto o modelo híbrido apresenta melhor desempenho em horizontes mais alargados, com um erro de 3.06% para 12 meses, contra 4.07% do LSTM.

No caso da série PPI, os resultados seguem uma tendência semelhante. Os modelos ARIMA e ES apresentam valores de MAPE mais elevados e crescentes com o horizonte de previsão, atingindo um máximo de 5.11% no ARIMA para 12 meses. O modelo LSTM tem um erro inicial muito reduzido (0.5127%), mas aumenta substancialmente com o horizonte (6.305%). O modelo híbrido mantém-se mais estável ao longo dos diferentes horizontes, com valores de MAPE que oscilam entre 1.39% e 3.64%.

Estes resultados mostram que o desempenho preditivo dos modelos difere consoante a abordagem e o horizonte de previsão, sendo notória a superioridade dos modelos neurais nos horizontes curtos e a maior consistência do modelo híbrido nos horizontes médios e longos.

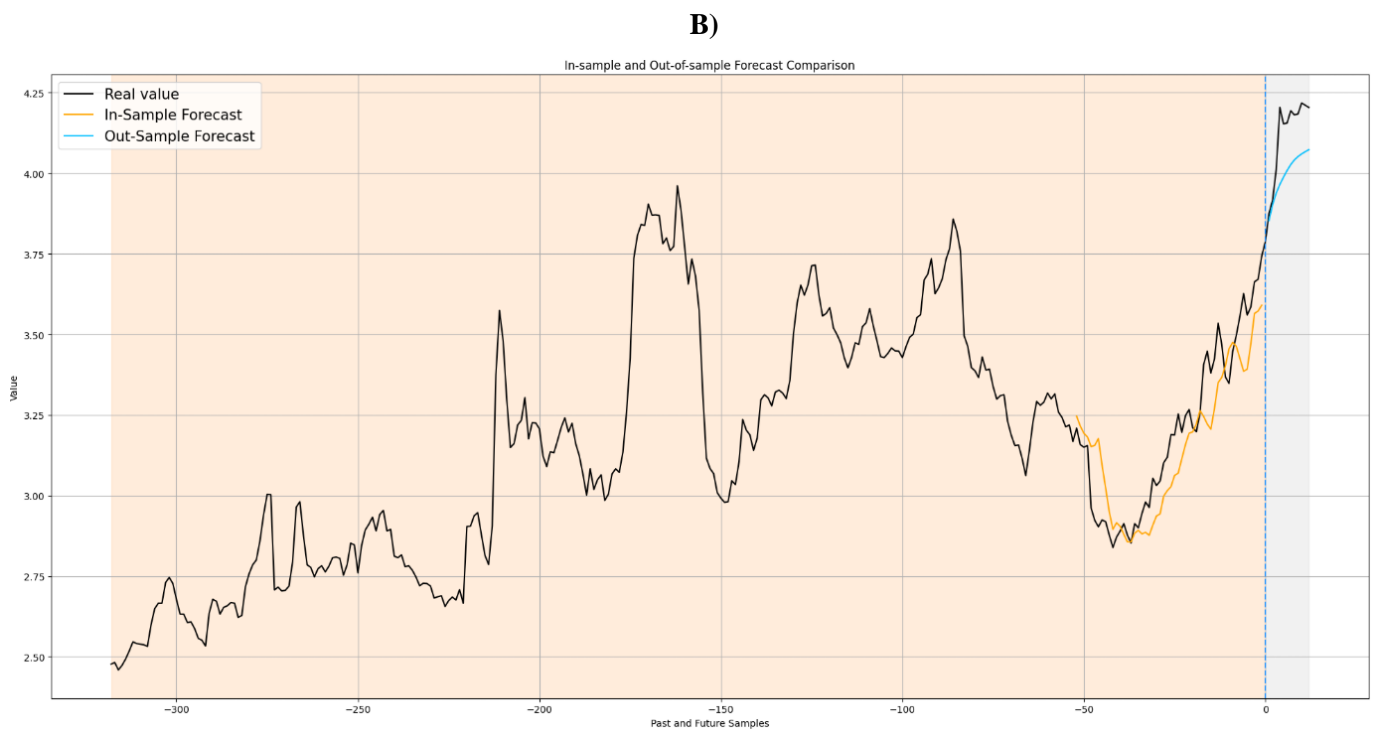



Fig. 8. Modelo DDN (treino e previsão) para a série do preço médio do leite ao consumidor: **A** Modelo LSTM; **B** Modelo Híbrido





Fig. 9. Modelo DDN (treino e previsão) para a série do PPI: **A** Modelo LSTM; **B** Modelo Híbrido

Tabela 3. Erros das previsões (MAPE)

Model	CPI			PPI		
	1 Months	3 Months	12 Months	1 Months	3 Months	12 Months
ARIMA	2.14 %	4.71 %	5.68 %	2.91 %	3.84 %	5.11 %
ES	2.26 %	4.74 %	5.23 %	2.16 %	2.91 %	4.44 %
LSTM	0.1578 %	1.199 %	4.071 %	0.5127 %	2.533 %	6.305 %
Modelo Híbrido	0.58 %	0.92 %	3.06 %	3.64 %	1.39 %	1.6 %

5. DISCUSSÃO

5.1. Contribuições teóricas e práticas

Os resultados obtidos demonstram uma diferença clara no desempenho dos modelos de previsão aplicados às séries temporais do preço do leite, tanto ao nível do consumidor (índice CPI) como ao nível do produtor (índice PPI). Os modelos avaliados ARIMA, Suavização Exponencial (ES), LSTM e o modelo Híbrido (ARIMA + LSTM) — apresentaram desempenhos distintos consoante o horizonte de previsão e a complexidade da série.

O modelo ARIMA, sendo adequado para captar estruturas lineares e tendências suaves, obteve resultados satisfatórios no curto prazo, mas apresentou perda de precisão em horizontes mais longos. A Suavização Exponencial (com estrutura aditiva, dada a ausência de sazonalidade significativa nas séries) teve bom desempenho inicial, mas também perdeu capacidade preditiva à medida que o horizonte aumentava. O modelo LSTM revelou-se eficaz na previsão da série CPI (preço ao consumidor), mas mostrou maior instabilidade na previsão do PPI, possivelmente devido à maior variabilidade da série de preços ao produtor.

O modelo Híbrido, por sua vez, conseguiu integrar os pontos fortes de ambas as abordagens: captou com eficácia a tendência determinística do preço do leite (via ARIMA) e modelou de forma robusta o componente não explicado (ruído) através de uma rede LSTM. Isto permitiu manter uma baixa amplitude de erro e uma boa aderência à tendência histórica, mesmo em previsões de 12 meses.

Estes resultados confirmam o que tem vindo a ser discutido na literatura sobre séries temporais agroalimentares: as flutuações nos preços de bens agrícolas como o leite resultam da interação entre tendências estruturais e fatores de curto prazo, como políticas públicas, variações sazonais e choques externos. A combinação de modelos lineares com redes neuronais tem sido apontada como uma solução eficaz para este tipo de dinâmica complexa.

O presente trabalho contribui para esta linha de investigação ao aplicar e validar uma estratégia híbrida numa aplicação concreta do setor agroalimentar, reforçando o seu potencial para previsão de preços agrícolas não estacionários e de comportamento volátil.

As implicações práticas desta análise são particularmente relevantes para os agentes do setor leiteiro — produtores, distribuidores, reguladores e decisores políticos. A previsão fiável do preço do leite ao produtor e ao consumidor pode apoiar a negociação de contratos de fornecimento com base em tendências reais e estimadas, permitir um planeamento mais eficaz da produção e da logística em função de ciclos de procura, e ainda contribuir para a formulação de políticas públicas ajustadas às pressões do mercado.

Do ponto de vista teórico, o estudo demonstra que a decomposição da série em componentes determinísticas e estocásticas, aliada ao uso de modelos complementares (ARIMA e LSTM), permite obter ganhos significativos de

previsão. Este tipo de abordagem poderá ser replicado noutros contextos agrícolas ou económicos com séries com comportamento semelhante, contribuindo para o avanço da modelação híbrida aplicada a dados reais.

5.2. Limitações e trabalho futuro

Apesar dos resultados promissores alcançados com os modelos desenvolvidos, este estudo apresenta algumas limitações importantes que devem ser reconhecidas. Em primeiro lugar, a análise foi baseada em séries temporais específicas os preços do leite ao consumidor (CPI) e ao produtor (PPI) com uma dimensão temporal limitada. Embora estas séries sejam economicamente relevantes, a sua extensão e granularidade podem ter condicionado a capacidade preditiva dos modelos, especialmente dos baseados em redes neuronais.

No que respeita à componente metodológica, destaca-se o desempenho do modelo LSTM, que, apesar de captar padrões complexos na série CPI, apresentou variações de erro mais acentuadas na previsão do PPI. Este comportamento pode ser parcialmente explicado pela sensibilidade da arquitetura LSTM à quantidade e qualidade dos dados disponíveis, bem como à escolha dos hiperparâmetros. O uso de validação cruzada com forward chaining atenuou esse efeito, mas não o eliminou totalmente.

Além disso, a ausência de sazonalidade nas séries analisadas limitou a capacidade de explorar a componente sazonal nos modelos de suavização exponencial e de aprofundar o impacto de técnicas clássicas com maior ênfase nessa estrutura. O modelo híbrido, embora robusto, depende de uma decomposição eficaz das componentes da série, o que implica que a qualidade da previsão poderá variar consoante a natureza da série em causa.

Como direções para trabalhos futuros, propõe-se a aplicação e validação da abordagem híbrida em séries temporais com diferentes características, como sazonalidade marcada ou elevada volatilidade. É também recomendável experimentar outras arquiteturas de redes neuronais, como GRU ou Transformers, que podem oferecer vantagens em termos de estabilidade e generalização. Adicionalmente, a incorporação de variáveis exógenas, como custo de produção, clima ou políticas de subsídio, poderá enriquecer os modelos e aumentar a precisão das previsões. Por fim, a análise mais sistemática do impacto da escolha dos hiperparâmetros e do número de lags, com recurso a métodos como grid search ou otimização bayesiana, e a promoção da interpretabilidade dos modelos neuronais, surgem como aspetos essenciais para aprofundar em investigações futuras.

6. CONCLUSÃO

Este estudo teve como principal objetivo avaliar e comparar diferentes abordagens de modelação para previsão do preço do leite nos Estados Unidos, tanto ao nível do consumidor (CPI) quanto do produtor (PPI). Para tal, foram aplicados modelos estatísticos clássicos (ARIMA, Suavização Exponencial), técnicas de deep learning (DNN) e, finalmente, um modelo híbrido que combina ARIMA com DNN.

A análise exploratória revelou séries com tendência bem definida, ausência de sazonalidade significativa e estrutura não estacionária, bem como dependências não lineares. Estes resultados justificaram a utilização de modelos que captam tanto estruturas determinísticas quanto comportamentos mais complexos.

Ao longo do processo de modelação, os modelos clássicos mostraram bom desempenho na captura da tendência histórica, mas apresentaram limitações na adaptação a oscilações mais recentes, sobretudo em horizontes de previsão mais longos. O modelo DNN destacou-se pela elevada precisão em previsões de curto prazo, especialmente na série CPI. No entanto, foi o modelo híbrido ARIMA-DNN que demonstrou maior consistência e robustez, mantendo bons níveis de erro mesmo em previsões de 12 meses e superando os restantes modelos em cenários com maior volatilidade.

A principal contribuição deste trabalho reside na integração eficaz de técnicas tradicionais com redes neuronais, demonstrando o potencial da modelação híbrida na previsão de preços agrícolas com elevada variabilidade. Para além da contribuição metodológica, os resultados têm implicações práticas diretas para agentes do setor leiteiro, oferecendo uma ferramenta preditiva que pode apoiar decisões relacionadas com produção, negociação e planeamento logístico.

De um modo geral, esta investigação demonstra como a análise e previsão de séries temporais, quando combinadas com metodologias complementares, pode gerar conhecimento com valor estratégico, contribuindo tanto para o avanço da ciência de dados como para a tomada de decisão em contextos económicos reais.

REFERENCIAS

Hyndman, R. J. , & A. G. (2021). *Forecasting: Principles and practice (3rd ed.)*. <https://otexts.com/fpp3/>

Ramos, F. R. (2021). *Data Science na Modelação e Previsão de Séries Económico-financeiras: das Metodologias Clássicas ao Deep Learning*.

Dados

U.S. Bureau of Labor Statistics via FRED. (n.d.-a). *Average Price: Milk, Fresh, Whole, Fortified (Cost per Gallon/3.8 Liters) in U.S. City Average (APU0000709112)*. Retrieved May 24, 2025, from <https://fred.stlouisfed.org/series/APU0000709112>

U.S. Bureau of Labor Statistics via FRED. (n.d.-b). *Producer Price Index by Industry: Fluid Milk Manufacturing: Fluid Milk and Cream, Bulk Sales (PCU3115113115111)*. Retrieved May 24, 2025, from <https://fred.stlouisfed.org/series/PCU3115113115111>

ANEXO

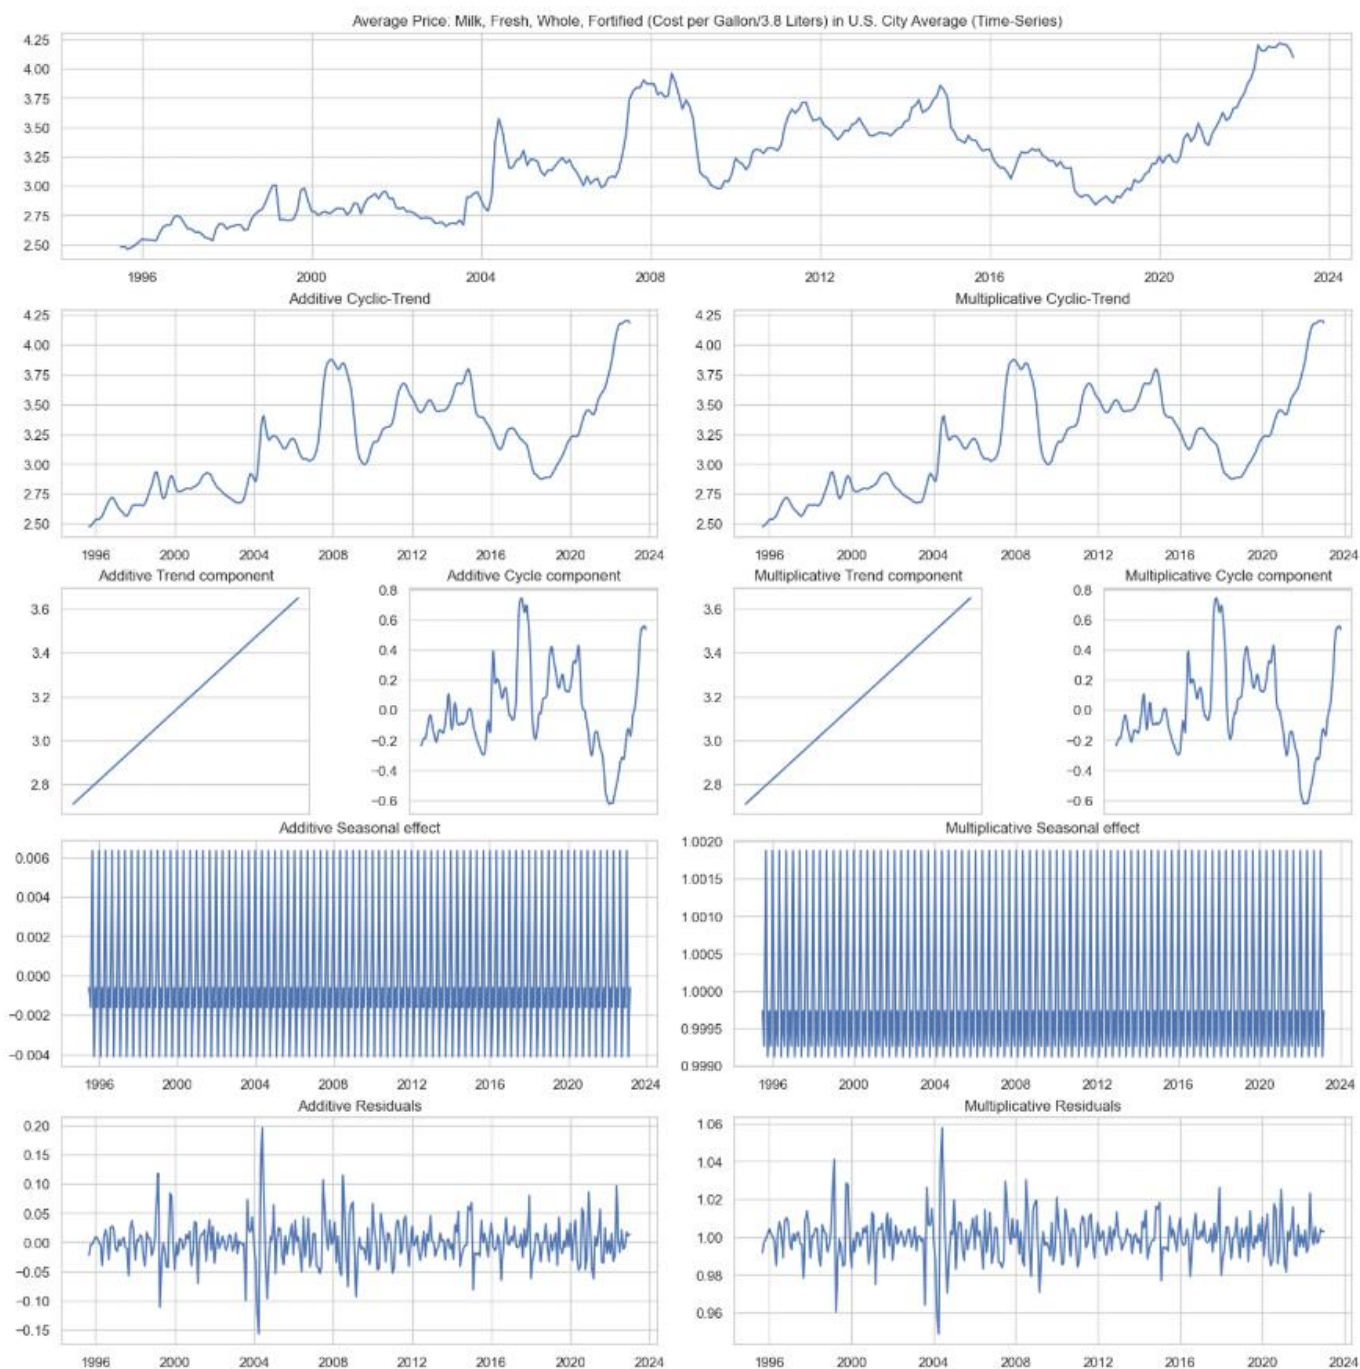


Fig. 10. Série do preço médio do leite ao consumidor(CPI): Representação grafica da Decomposição da série

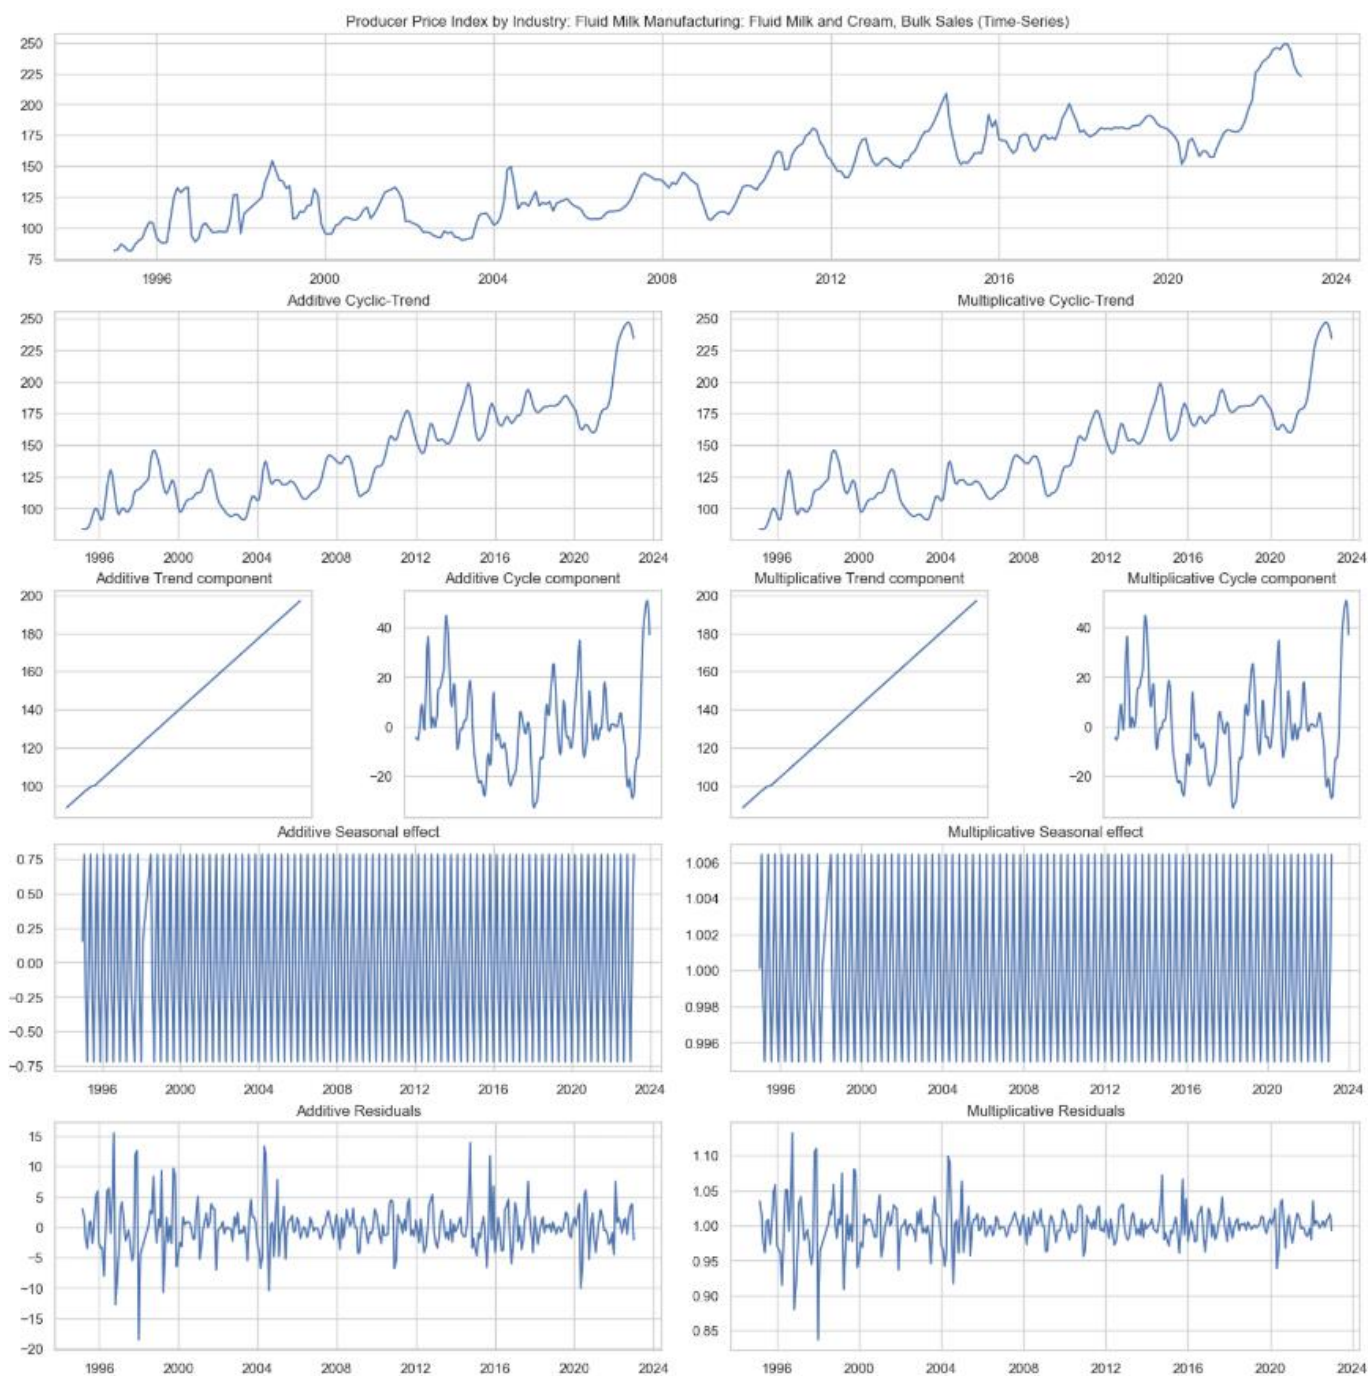


Fig. 11. Série PPI: Representação grafica da Decomposição da série




Fig. 12. Previsões para o modelo DNN: **A** CPI; **B** PPI




Fig. 13. Previsões para o modelo Híbrido: **A** CPI; **B** PPI